

Binarizarea și aplicarea operațiilor morfologice


Primul pas al algoritmului constă în segmentarea structurilor dendritice din imaginea microscopică. Pentru aceasta au fost implementate două metode de binarizare: binarizarea globală și binarizarea adaptivă.

Binarizarea reprezintă procesul de transformare a unei imagini în tonuri de gri într-o imagine binară, în care fiecare pixel primește una dintre cele două valori posibile (0 pentru fundal și 255 pentru obiect). Scopul acestei operații este separarea structurilor de interes de fundal.

În cazul binarizării globale se utilizează un singur prag pentru întreaga imagine. Pixelii cu intensitate mai mare decât pragul sunt clasificați ca obiect, iar cei cu intensitate mai mică sunt clasificați ca fundal. Alegerea unui prag optim se bazează pe analiza histogrammei imaginii. Histograma reprezintă distribuția frecvențelor nivelurilor de gri și permite identificarea eventualelor clase de pixeli corespunzătoare fundalului și obiectelor.

Binarizarea globală este eficientă în special pentru imagini cu histogramă bimodală, unde fundalul și obiectele formează două grupuri distincte de intensități. În imaginile microscopice cu dendrite analizate în cadrul proiectului, histograma este puternic concentrată în zona intensităților mici (aproximativ 0–15), ceea ce indică prezența unui fundal dominant și a unor structuri dendritice slab evidențiate. În aceste condiții, utilizarea unui singur prag global poate conduce la pierderea unor detalii importante sau la segmentarea incompletă a dendritelor.

Din acest motiv a fost implementată și o metodă de binarizare adaptivă, care calculează un prag local pentru fiecare regiune a imaginii. Această abordare permite compensarea variațiilor locale de iluminare și conduce la o segmentare mai robustă a structurilor dendritice.



Binarizarea adaptivă folosind imaginea integrală.

IMAGINE INTEGRALĂ (SUMMED AREA TABLE)

Imaginea integrală $S(i, j)$ reține suma tuturor pixelilor din dreptunghiul cu colțul în $(0, 0)$ și colțul în (i, j) (inclusiv).

Fie $I(i, j)$ valoarea pixelului din imaginea originală.

FORMULA DE RECURENȚĂ:
 $S(i, j) = I(i, j) + S(i-1, j) + S(i, j-1) - S(i-1, j-1)$

$S(i-1, j)$ = suma de deasupra
 $S(i, j-1)$ = suma din stânga
 $S(i-1, j-1)$ = zona dublată (colțul stânga-sus)
 $I(i, j)$ = pixelul curent

De ce scădem $S(i-1, j-1)$?
 Pentru că este inclus atât în $S(i-1, j)$, cât și în $S(i, j-1)$, deci este adunat de două ori.

EXEMPLU

Imagine originală I					
	0	1	2	3	4
0	3	1	2	4	1
1	0	2	1	3	2
2	4	0	1	2	1
3	1	1	0	1	0

Imagine integrală S					
	0	1	2	3	4
0	3	4	6	10	11
1	3	6	9	16	19
2	7	10	14	22	26
3	8	12	16	25	30

✓ Fiecare element $S(i, j)$ conține suma tuturor pixelilor din dreptunghiul $(0, 0) - (i, j)$.
 ✓ Colțul din dreapta-jos al unui dreptunghi mare conține deja suma întregii zone.

CUM CALCULĂM SUMA ORICĂRUI DREPTUNGHI ÎN $O(1)$

Imagine integrală S

Suma dreptunghiului = $D - B - C + A$

$sum = S(y_2, x_2) - S(y_1-1, x_2) - S(y_2, x_1-1) + S(y_1-1, x_1-1)$

$A = (y_1-1, x_1-1)$ colțul stânga-sus
 $B = (y_1-1, x_2)$ colțul dreapta-sus
 $C = (y_2, x_1-1)$ colțul stânga-jos
 $D = (y_2, x_2)$ colțul dreapta-jos

Doar 4 accesări în imaginea integrală, indiferent de dimensiunea dreptunghiului!

Exemplu numeric

Folosim exemplul de mai sus.
 Dreptunghi: de la $(y_1, x_1) = (1, 1)$ la $(y_2, x_2) = (2, 3)$

$A = S(0, 0) = 3$
 $B = S(0, 3) = 10$
 $C = S(2, 0) = 7$
 $D = S(2, 3) = 22$

$sum = 22 - 10 - 7 + 3 = 8$

Verificare în imaginea originală:
 $2 - 1 + 3 + 2 = 8$ ✓

IDEE CHEIE: Imaginea integrală transformă problema de a calcula suma pixelilor într-un dreptunghi dintr-o operație costisitoare ($O(n^2)$) într-una constantă ($O(1)$).

Binarizarea adaptivă utilizează un prag local calculat pentru fiecare pixel al imaginii. Spre deosebire de binarizarea globală, unde se folosește un singur prag pentru întreaga imagine, binarizarea adaptivă determină un prag diferit pentru fiecare regiune a imaginii. Această abordare este mai robustă în cazul imaginilor microscopice, unde iluminarea nu este uniformă, iar structurile dendritice au intensități variabile.

Pentru fiecare pixel se consideră o fereastră locală de dimensiune $w \times w$, centrată în jurul acestuia. Se calculează media intensităților din fereastră, iar pragul local este definit ca:

$$T(x, y) = \frac{\sum_{(i, j) \in W} I(i, j)}{|W|} - C$$

unde:

- W reprezintă fereastra locală;
- $|W|$ reprezintă numărul de pixeli din fereastră;
- $I(i, j)$ reprezintă intensitatea pixelului (i, j) ;
- C reprezintă o constantă de ajustare utilizată pentru controlul sensibilității segmentării.

După calcularea pragului local, pixelul este clasificat ca obiect sau fundal prin compararea intensității sale cu valoarea pragului.

O implementare directă a acestei metode necesită calcularea sumei tuturor pixelilor din fiecare fereastră locală. Pentru o imagine de dimensiune $n \times n$, complexitatea algoritmului este:

$$O(w^2 \cdot n^2)$$

deoarece pentru fiecare pixel trebuie parcurse toate cele w^2 elemente ale ferestrei. Pentru imagini de dimensiuni mari și ferestre extinse, costul computațional devine foarte ridicat.

Pentru optimizarea algoritmului a fost utilizată imaginea integrală (Summed Area Table). Imaginea integrală este o structură de date în care fiecare element conține suma tuturor pixelilor aflați în dreptunghiul delimitat de colțul stânga-sus al imaginii și poziția curentă. Aceasta se calculează folosind relația recursivă:

$$S(i, j) = I(i, j) + S(i - 1, j) + S(i, j - 1) - S(i - 1, j - 1)$$

unde:

- $I(i, j)$ reprezintă valoarea pixelului curent;
- $S(i - 1, j)$ reprezintă suma regiunii aflate deasupra;
- $S(i, j - 1)$ reprezintă suma regiunii aflate în stânga;
- $S(i - 1, j - 1)$ este scăzut pentru a elimina zona contabilizată de două ori.

După construirea imaginii integrale, suma pixelilor din orice fereastră dreptunghiulară poate fi calculată prin accesarea a doar patru valori:

$$\text{sum} = S(y_2, x_2) - S(y_1 - 1, x_2) - S(y_2, x_1 - 1) + S(y_1 - 1, x_1 - 1)$$

Astfel, suma unei ferestre se obține în timp constant, indiferent de dimensiunea acesteia. Complexitatea calculului pentru fiecare pixel devine $O(1)$, iar complexitatea totală a binarizării adaptive se reduce la:

$$O(n^2)$$

Această optimizare permite procesarea eficientă a imaginilor microscopice de rezoluție mare și face posibilă utilizarea ferestrelor locale fără creșterea semnificativă a timpului de execuție.

Operații morfologice și eliminarea componentelor conexe


În urma procesului de binarizare se obține o imagine binară care conține, pe lângă structurile dendritice de interes, și numeroase artefacte generate de zgomotul prezent în imaginea originală. Aceste artefacte apar sub forma unor regiuni mici sau a unor pixeli izolați care nu aparțin structurii dendritice.

Pentru reducerea zgomotului au fost aplicate operații morfologice. Mai întâi s-a utilizat operația de eroziune, care elimină obiectele mici și subțiază regiunile binare. Ulterior s-a aplicat dilatarea, care reconstruiește forma structurilor relevante păstrate după eroziune. Combinația dintre cele două operații reprezintă o deschidere morfologică și este utilizată pentru eliminarea artefactelor punctuale de dimensiuni reduse.


Deși operațiile morfologice reduc semnificativ zgomotul, în imagine rămân în continuare componente conexe mici care nu aparțin dendritelor. Pentru eliminarea acestora s-a realizat o analiză a componentelor conexe folosind algoritmul Breadth First Search (BFS). Fiecare componentă conexă este etichetată și se calculează aria acesteia, definită ca numărul de pixeli care aparțin componentei.

Componentele a căror arie este mai mică decât un prag prestabilit sunt considerate zgomot și sunt eliminate din imagine. În acest mod sunt păstrate doar structurile dendritice semnificative din punct de vedere morfologic.

După aplicarea operațiilor morfologice și a filtrării componentelor conexe, se obține o imagine binară curățată care va fi utilizată în etapele următoare ale algoritmului: calculul transformatei de distanță, scheletizarea și analiza morfologică a dendritelor și a spinilor dendritici.



Imaginea binara cu artefacte



Imaginea binara fara artefacte

Transformata de distanță

După obținerea imaginii binare curate, următorul pas al algoritmului este calculul transformatei de distanță (Distance Transform). Această operație asociază fiecărui pixel aparținând obiectului distanța până la cel mai apropiat pixel de fundal. Pixelii aflați în apropierea marginilor structurii vor avea valori mici, iar pixelii situați în zona centrală vor avea valori mai mari.

Transformata de distanță a fost implementată printr-un algoritm cu două parcurgeri ale imaginii. În prima parcurgere (forward pass), imaginea este scanată de la stânga sus către dreapta jos, iar fiecare pixel își actualizează valoarea pe baza vecinilor deja procesați. În a doua parcurgere (backward pass), imaginea este scanată în sens invers, de la dreapta jos către stânga sus, pentru a propaga informația și din direcțiile opuse. Costul deplasărilor orizontale și verticale este considerat egal cu 1, iar costul deplasărilor diagonale este $\sqrt{2}$.

Rezultatul este o hartă de distanțe care oferă informații despre grosimea locală a structurilor dendritice. Această hartă este utilizată ulterior pentru estimarea lățimii capului spinilor dendritici și pentru separarea trunchiului dendritic de ramurile secundare în etapa de prunire a scheletului.

Scheletizare bazată pe maxime locale ale transformatei de distanță


O metodă simplă de obținere a scheletului utilizează transformata de distanță calculată anterior. Ideea principală este că pixelii aflați pe axa mediană a unei structuri au valori mai mari ale

transformatei de distanță decât vecinii lor, deoarece sunt situați mai departe de marginile obiectului.

Pentru fiecare pixel al obiectului se compară valoarea transformatei de distanță cu valorile celor opt vecini din vecinătatea 3×3 . Dacă valoarea pixelului curent reprezintă un maxim local, acesta este considerat parte a scheletului. În caz contrar, pixelul este eliminat.

Avantajul acestei metode este simplitatea implementării și faptul că identifică rapid punctele situate în apropierea axei mediane a structurii. Totuși, metoda prezintă un dezavantaj major: nu garantează păstrarea conectivității topologice. În practică, scheletul rezultat conține numeroase întreruperi și fragmente izolate, deoarece unii pixeli necesari conectării ramurilor nu reprezintă maxime locale și sunt eliminați.

Din acest motiv, scheletul obținut prin detectarea maximelor locale nu poate fi utilizat direct pentru analiza dendritelor și a spinilor dendritici. Pentru obținerea unui schelet continuu și conectat a fost utilizat ulterior algoritmul Zhang-Suen de thinning, care păstrează topologia structurii în timpul procesului de subțiere.



Schelet cu local maximum.

Scheletizarea utilizând algoritmul Zhang-Suen

Pentru obținerea unui schelet continuu și conectat a fost utilizat algoritmul Zhang-Suen de thinning. Acesta reprezintă una dintre cele mai utilizate metode de scheletizare pentru imagini binare deoarece reduce progresiv grosimea obiectelor până la o lățime de un pixel, păstrând în același timp topologia și conectivitatea structurii.

Algoritmul funcționează iterativ. La fiecare iterație sunt analizate toate punctele obiect de pe conturul structurii și sunt eliminate doar acele puncte care nu afectează conectivitatea scheletului. Procesul este repetat până când nu mai există pixeli care pot fi eliminați.

Pentru fiecare pixel P_1 sunt analizați cei opt vecini ai săi:

$$P_2, P_3, P_4, P_5, P_6, P_7, P_8, P_9$$

ordonați în sensul acelor de ceasornic.

Un pixel este eliminat numai dacă sunt îndeplinite simultan următoarele condiții:

1. Numărul vecinilor activi

Numărul vecinilor obiect trebuie să fie cuprins între 2 și 6:

$$2 \leq B(P_1) \leq 6$$

unde

$$B(P_1) = P_2 + P_3 + P_4 + P_5 + P_6 + P_7 + P_8 + P_9$$

reprezintă numărul total de vecini activi.

2. O singură tranziție $0 \rightarrow 1$

Parcurgând vecinii în sens circular trebuie să existe exact o tranziție de la fundal la obiect:

$$A(P_1) = 1$$

Această condiție garantează că eliminarea pixelului nu va fragmenta structura.

3. Prima condiție topologică

În prima subiterație trebuie să fie adevărat:

$$P_2 \cdot P_4 \cdot P_6 = 0$$

și

$$P_4 \cdot P_6 \cdot P_8 = 0$$

Astfel se evită eliminarea unor pixeli esențiali pentru conectivitate.

4. A doua condiție topologică

În a doua subiterație se utilizează condițiile:


$$P_2 \cdot P_4 \cdot P_8 = 0$$

și

$$P_2 \cdot P_6 \cdot P_8 = 0$$

Aceste condiții sunt complementare celor din prima subiterație și permit subțierea uniformă a structurii din toate direcțiile.

Procesul continuă până când două iterații consecutive nu mai produc modificări. Rezultatul final este un schelet cu grosime de un pixel care păstrează forma și conectivitatea dendritelor, fiind adecvat pentru detectarea punctelor terminale, a punctelor de joncțiune și pentru analiza spinilor dendritici.



Clasificarea punctelor din schelet

După obținerea scheletului este necesară identificarea punctelor caracteristice ale structurii dendritice. Aceste puncte sunt utilizate ulterior pentru separarea trunchiului dendritic de spini și pentru analiza topologiei scheletului.

Au fost investigate două metode de clasificare a punctelor din schelet:


- clasificarea pe baza numărului de vecini activi;
- clasificarea pe baza numărului de tranziții în vecinătatea circulară.

Clasificarea pe baza numărului de vecini

În prima variantă, pentru fiecare pixel al scheletului se numără cei opt vecini din vecinătatea 3×3 . Clasificarea se realizează astfel:

- pixel cu un singur vecin activ $\rightarrow$ punct terminal (endpoint);
- pixel cu doi vecini activi $\rightarrow$ punct simplu;
- pixel cu trei sau mai mulți vecini activi $\rightarrow$ punct de joncțiune (junction point).

Metoda este simplă și eficientă din punct de vedere computațional, însă prezintă un dezavantaj important. În zonele de bifurcație, mai mulți pixeli adiacenți pot avea simultan trei sau mai mulți vecini activi. În loc să se obțină un singur punct de joncțiune, apare o întreagă regiune etichetată ca joncțiune. Acest fenomen produce secvențe de puncte de joncțiune și îngreunează urmărirea corectă a ramurilor scheletului.



Clasificarea pe baza numărului de tranziții

Pentru a elimina această problemă a fost utilizată o a doua metodă bazată pe numărul de tranziții dintre valorile 0 și 1 în vecinătatea circulară a fiecărui pixel. Vecinii sunt parcurși în sensul acelor de ceasornic, iar se numără tranzițiile de forma:


$$0 \rightarrow 1$$

Numărul de tranziții oferă o descriere mai robustă a structurii locale a scheletului.

Clasificarea utilizată în implementarea finală este:

- o tranziție $\rightarrow$ punct terminal;
- două tranziții $\rightarrow$ punct simplu;
- trei sau mai multe tranziții $\rightarrow$ punct de joncțiune.

Această abordare produce o localizare mult mai precisă a punctelor de bifurcație și evită apariția regiunilor extinse de joncțiuni observate în metoda bazată exclusiv pe numărul de vecini. Din acest motiv, clasificarea bazată pe tranziții a fost utilizată în toate etapele ulterioare ale algoritmului.



Extragerea trunchiului dendritic prin eliminarea iterativă a spinilor

După identificarea punctelor terminale și a punctelor de joncțiune, următorul obiectiv este separarea trunchiului dendritic principal de spinii dendritici. Ideea de bază este că spinii reprezintă ramuri scurte atașate trunchiului principal, în timp ce trunchiul dendritic formează cea mai importantă structură a scheletului.

Pentru fiecare punct terminal detectat se urmărește ramura din care acesta face parte. Pornind din punctul terminal, algoritmul parcurge succesiv pixelii vecini ai scheletului până când întâlnește primul punct de joncțiune. Toți pixelii vizitați sunt salvați într-un vector care reprezintă ramura curentă.

Lungimea ramurii este estimată prin numărul de pixeli conținuți în acest vector. Dacă lungimea obținută este mai mică decât un prag prestabilit α , ramura este considerată spin dendritic și este eliminată din schelet. Eliminarea se realizează prin transformarea tuturor pixelilor ramurii în pixeli de fundal.


Procesul este repetat pentru toate punctele terminale ale scheletului. După eliminarea unei generații de spini, apar noi puncte terminale, deoarece unele ramuri devin mai scurte. Din acest motiv, clasificarea punctelor și procesul de pruning sunt executate iterativ până când două iterații consecutive nu mai produc modificări. Structura rămasă reprezintă trunchiul dendritic principal.

O dificultate importantă întâlnită în implementare a fost modificarea simultană a punctelor de joncțiune în timpul procesului de pruning. Într-o versiune inițială a algoritmului, clasificarea punctelor era actualizată în timpul parcurgerii ramurilor. Acest lucru conducea la modificarea unor puncte de joncțiune înainte ca toate ramurile să fie procesate, ceea ce producea eliminarea accidentală a unor segmente aparținând trunchiului principal. Efectul era dificil de observat deoarece scheletul dendritic are o topologie complexă, iar erorile apăreau doar în anumite


configurații

de

ramificații.



Scheletul initial.



Scheletul dupa eliminarea spinilor.

Separarea trunchiului dendritic de spinii dendritici

Procesul de eliminare a spinilor este aplicat iterativ până la convergență. La început se pornește de la scheletul complet obținut prin algoritmul Zhang-Suen. Pentru fiecare iterație sunt identificate punctele terminale și punctele de joncțiune, iar ramurile scurte sunt eliminate prin algoritmul de pruning descris anterior.

După fiecare iterație se compară numărul de pixeli rămași în schelet. Dacă două iterații consecutive produc același număr de pixeli, procesul este considerat convergent și se oprește. În acest moment se presupune că toate ramurile scurte au fost eliminate, iar structura rămasă reprezintă trunchiul dendritic principal.

Fie:

$$S$$

scheletul complet al dendritei și al spinilor, iar


$$D$$

trunchiul dendritic obținut după procesul iterativ de pruning. Imaginea care conține exclusiv spinii dendritici poate fi obținută prin diferența dintre cele două structuri:

$$P = S - D$$

unde P reprezintă mulțimea pixelilor aparținând spinilor dendritici.

Această observație simplifică semnificativ etapa de segmentare a spinilor. După obținerea trunchiului dendritic, toți pixelii care aparțin acestuia sunt eliminați din scheletul original, iar pixelii rămași formează imaginea spinilor. Fiecare componentă conexă din această imagine corespunde unui spin dendritic individual.



Obținerea spinilor

Calculul metricilor morfologice ale spinilor dendritici

După separarea spinilor dendritici de trunchiul principal, fiecare spin este analizat individual pentru a extrage informații morfologice relevante. În acest scop se aplică o nouă analiză a componentelor conexe asupra imaginii care conține exclusiv spinii dendritici.

Fiecare componentă conexă este considerată un spin individual și este etichetată utilizând algoritmul Breadth First Search (BFS). În timpul procesului sunt memorizați toți pixelii care aparțin spinului curent, ceea ce permite calculul diferitelor caracteristici morfologice.

Numărul de spini

Numărul total de componente conexe detectate în imaginea spinilor reprezintă numărul total de spini dendritici identificați:

$$N_{spines} = N_{components}$$

Această metrică este importantă deoarece densitatea spinilor este asociată cu nivelul de conectivitate sinaptică al neuronului.

Lungimea spinilor

Pentru fiecare spin se calculează lungimea sa ca număr de pixeli care aparțin componentei conexe:

$$L_i = |C_i|$$

unde C_i reprezintă mulțimea pixelilor din componenta conexă corespunzătoare spinului i .

Pe baza lungimilor individuale se calculează lungimea medie:

$$\bar{L} = \frac{1}{N} \sum_{i=1}^N L_i$$

și deviația standard:

$$\sigma_L = \sqrt{\frac{1}{N} \sum_{i=1}^N (L_i - \bar{L})^2}$$

Aceste valori oferă informații despre distribuția dimensiunilor spinilor din imagine.

Lățimea capului spinului

Pentru estimarea lățimii capului spinului se utilizează transformata de distanță calculată anterior. Pentru punctele terminale ale fiecărui spin se extrage valoarea locală a transformatei de distanță. Deoarece această valoare reprezintă aproximativ raza locală a structurii, lățimea este estimată prin:

$$W = 2 \cdot DT$$


unde DT este valoarea transformatei de distanță în punctul terminal.

Pentru fiecare spin se calculează lățimea medie a capului, iar ulterior se determină media și deviația standard pentru întreaga populație de spini:

$$\bar{W} = \frac{1}{N} \sum_{i=1}^N W_i$$
$$\sigma_W = \sqrt{\frac{1}{N} \sum_{i=1}^N (W_i - \bar{W})^2}$$

Histograma lungimilor

Pentru analiza distribuției lungimilor este construită o histogramă în care fiecare bin reprezintă o lungime posibilă exprimată în pixeli. Histograma permite observarea distribuției statistice a spinilor și identificarea eventualelor clase dominante de dimensiuni.



Histograma de lungimi

REZUMAT	
Metrică	Valoare
Număr total spine-uri	97
Lungime minimă	1 pixeli
Lungime maximă	178 pixeli
Lungime medie	27.58 pixeli
Deviația standard	30.62 pixeli
Lățime medie cap	7.87 pixeli
Deviația standard (lățime cap)	2.70 pixeli

Rezultate finale.